

Evolutionary Computing

Naive Suche

Prof. Dr. Veronika Lesch

INF23

Copyright

Alle Materialien in diesem Kurs werden nur für Ihre persönliche Nutzung bereitgestellt. Das Teilen oder Weitergeben der Vorlesungs- und Übungsmaterialien an Dritte ist generell untersagt!

- 1 Motivation
- 2 Naive Suche - Grid Search
- 3 Naive Suche - Random Search
- 4 Ausblick Lokale Suche
- 5 Quellen

Motivation

Think–Pair–Share: Was ist hier falsch?

Sie haben 15min Zeit für Ihr Frühstück und folgende Optionen:

- Toast: 3min (Sättigung 2)
- Müsli: 5min (Sättigung 4)
- Smoothie: 10min (Sättigung 6)

Was sollten Sie frühstücken um Ihre Sättigung zu maximieren?

Phase 1 – Think (2–3 Minuten)

Gegeben ist folgende Modellierung des Frühstück-Problems:

$$\text{Zielfunktion: } \max 2x_1 + 4x_2 + 6x_3$$

$$\text{Nebenbedingung: } 3x_1 + 5x_2 + 10x_3 = 15$$

$$\text{Variablen: } x_i \geq 0$$

Frage: Was ist an dieser Modellierung problematisch?

Think–Pair–Share: Was ist hier falsch?

Phase 2 – Pair (5 Minuten Partnerarbeit)

Diskutieren Sie:

- Welche Annahmen sind unrealistisch oder fehlen?
- Welche Modellierungsentscheidungen sind ungünstig?
- Wie würden Sie das Modell verbessern?

Phase 3 – Share

Sammeln im Plenum:

- typische Fehler
- alternative Modellierungen

Showcase - Manuelle Optimierung



[1]

Naive Suche - Grid Search

Naive Suchverfahren als Baseline

Ohne Baseline lässt sich kein Verfahren sinnvoll bewerten. Naive Suche ist die klassische Baseline: keinerlei Problem-Wissen, maximale Allgemeinheit.

Eigenschaften naiver Suchverfahren:

- **Einfach:** wenige Parameter, leicht implementierbar
- **Robust:** keinerlei Annahmen über f oder $\mathcal{X}$
- **Parallelisierbar:** Samples sind unabhängig
- **Naiv:** kein Lernen, keine Anpassung
- **Baseline:** Jeder spätere Algorithmus muss besser sein – sonst lohnt er sich nicht

Grid Search

- Suchraum eines Problems kann diskret, kontinuierlich oder gemischt (MILP) sein
 - Brute Force schlägt bei kontinuierlichen Problemen fehl
- Welche Punkte sollen getestet werden?


Idee: Diskretisierung des Suchraums und Bewertung aller Gitterpunkte.

$$\mathcal{X}_{\text{grid}} = \{x_{\min} + i \cdot h \mid i = 0, \dots, k - 1\}^d, \quad h = \frac{x_{\max} - x_{\min}}{k - 1}$$


Grid Search

Grid Search - $f(x,y) = (x)^2 + (y)^2$

3D-Oberflächenplot



Konturplot



Ziel: Minimierung | Optimum: (0, 0), $f = 0$

Grid Search – Pseudocode

Algorithm 1 Grid Search

```
1: function GRIDSEARCH(grid, f)  
2:   best  $\leftarrow$  None  
3:   for  $x \in \textit{grid}$  do  
4:     if  $f(x) > f(\textit{best})$  then  
5:       best  $\leftarrow$  x  
6:     end if  
7:   end for  
8:   return best  
9: end function
```

Vorteile:

- Reproduzierbar, deterministisch
- Gut für niedrige Dimensionen ($d \leq 3$)
- Einfache Parallelisierung
- Standard-Baseline im ML (GridSearchCV [3])

Nachteile:

- Fluch der Dimensionalität: k^d Punkte – exponentielles Wachstum
- Beispiel: $k = 10, d = 6 \rightarrow 10^6$ Auswertungen
- Keine Anpassung an Problemstruktur
- Gitterauflösung als Parameter

- Implementieren Sie Grid Search für kontinuierliche Funktionen 2er Variablen.
- Nutzen Sie das zur Verfügung gestellte Web Tool für die Evaluierung von Punkten

Naive Suche - Random Search

Random Search

- Brute Force ist in der Realität kaum anwendbar (Laufzeit, Dimensionalität)
 - Grid Search leidet unter dem Fluch der Dimensionalität: k^d Punkte
 - Viele Gitterpunkte liegen in irrelevanten Regionen des Suchraums
- Lässt sich die Effizienz durch zufällige Stichproben verbessern?

Idee: Zufälliges Sampling aus dem Suchraum und Bewertung der gezogenen Punkte.

$$\mathcal{X}_{\text{rand}} = \{x^{(i)} \sim \mathcal{U}(\mathcal{X}) \mid i = 1, \dots, N\}$$

Random Search

Algorithm 2 Random Search

```
1: function RANDOMSEARCH( $D, f, N$ )  
2:    $best \leftarrow \text{None}$   
3:   for  $i = 1$  to  $N$  do  
4:      $x \leftarrow \text{UniformSample}(D)$   
5:     if  $f(x) > f(best)$  then  
6:        $best \leftarrow x$   
7:     end if  
8:   end for  
9:   return  $best$   
10: end function
```

D : Suchraum, N : Anzahl zufälliger Stichproben, [6]

Vorteile:

- Skaliert linear: N Auswertungen unabhängig von D
- Deckt irrelevante Dimensionen effizienter ab
- Reproduzierbar durch Fixierung des Seeds
- Einfache Parallelisierung
- Standard-Baseline im ML (RandomizedSearchCV [4])

Nachteile:

- Keine Garantie, optimale Region zu treffen
- Keine Anpassung an Problemstruktur
- Ergebnisse variieren bei unterschiedlichem Seed
- Stichprobenanzahl N als Parameter



[1]

- Aufgabe 1: Random Search für das Knapsack Problem
- Aufgabe 2: Wann funktioniert welcher Algorithmus?

Grid Search vs. Random Search

Grid Search

- Samples auf festem Raster
- Viele redundante Punkte in unwichtigen Dimensionen
- Kann wichtige Regionen systematisch *verpassen*, wenn Gitter zu grob

Random Search

- Samples unkorreliert im Raum
- Jeder Sample trägt potenziell neue Information
- [5]: *Random Search outperforms Grid Search* bei ML-Tuning

Grenzen naiver Suche

Fundamentale Probleme:

- 1 **Kein Gedächtnis:** Jeder Sample ist unabhängig – erfolgreiche Regionen werden nicht intensiver besucht
- 2 **Keine Adaption:** Die Verteilung der Samples ändert sich nicht mit der Erfahrung
- 3 **Kein Gradient:** Keine Richtungsinformation aus bisherigen Auswertungen
- 4 **Skalierung:** Aufwand wächst exponentiell mit der Problemdimension

Was wir brauchen:

- Mechanismus, der *gute* Regionen bevorzugt
- Mechanismus, der neue Lösungen aus alten erzeugt
- Mechanismus, der Vielfalt erhält

Gruppenarbeit - Mindmap

- Sie erhalten eine Menge von Begriffen
- Erstellen Sie daraus zu dritt eine Mindmap, die alle genannten Begriffe enthält
- Beschriften Sie Verbindungen passend (z.B. beeinflusst, gehört zu, führt zu...)
- Welche Begriffe fehlen aktuell in der Mindmap?



[2]

Ausblick Lokale Suche

A misty forest scene with large trees and moss on the ground. The image is a full-page background for a presentation slide. It features a dense forest of tall, slender trees with thick, moss-covered trunks. The ground is covered in a thick layer of green moss. The atmosphere is misty and ethereal, with soft light filtering through the trees. The text "... beenden Sie die Geschichte." is centered in the middle of the image.

... beenden Sie die Geschichte.

Quellen

Quellen I

- [1] Generiert von Microsoft Copilot.
[Online; accessed 2026-03-12].
- [2] Generiert von Microsoft Copilot.
[Online; accessed 2026-03-17].
- [3] GridSearchCV — scikit-learn 1.8.0 documentation.
[Online; accessed 2026-03-12].
- [4] RandomizedSearchCV — scikit-learn 1.8.0 documentation.
[Online; accessed 2026-03-12].
- [5] James Bergstra and Yoshua Bengio.
Random search for hyper-parameter optimization.
Journal of Machine Learning Research, 13:281–305, 2012.

[6] Sean Luke.

Essentials of Metaheuristics.

Lulu, second edition, 2013.

Available at <https://people.cs.gmu.edu/~sean/book/metaheuristics/>.